



Projet du Module obligatoire M5 « Culture digitale »

Intitulé de formation : Fondamentaux de Python

**Analyse statistique des effets du seed priming et des pulvérisations
foliaires sur les performances agronomiques du blé tendre à l'aide
de Python**

Réalisé par : H'DAIDANE Hanae, doctorante en 3^{ème} année

Structure de Recherche : Équipe de Recherche en Biotechnologies et Génie des
Biomolécules (ERBGB) / Département de Biologie

Encadré par : EL GALIOU Ouïam

Sous la supervision de : Pr. AZMANI Abdellah | Pr. EL HAJI Essaid | Pr. BOUKROUH Ikhlass
| Mlle. MAYOUCHE Ibtihal

Année universitaire : 2025-2026

Sommaire

Résumé	2
1. Introduction	3
2. Présentation du dataset	4
3. Questions d'analyse	6
4. Méthodologie	7
4.1. Chargement et exploration des données	7
4.2. Nettoyage et préparation des données	9
4.3. Analyse descriptive et visualisation adaptée.....	10
4.4. Analyse des relations entre variables	29
4.5. Application d'un test d'hypothèse	37
5. Interprétation des Résultats et Conclusion	44
6. Références	45

Résumé

L'amélioration des performances agronomiques du blé constitue un enjeu important pour maintenir sa productivité dans des conditions de culture de plus en plus contraignantes. Parmi les stratégies agronomiques développées, le Seed Priming et l'application foliaire de micronutriments représentent des approches susceptibles d'améliorer la croissance, le rendement et la qualité des grains. Parallèlement, l'exploitation des données issues de telles expérimentations nécessite des outils statistiques et informatiques permettant d'identifier les tendances, les relations entre les caractères agronomiques et les effets des traitements. Dans ce contexte, la présente étude a porté sur l'analyse, sous Python, d'un jeu de données relatif à l'effet du Seed Priming au sulfate de zinc (ZnSO_4) et de différentes pulvérisations foliaires sur le blé tendre (*Triticum aestivum* L.) cultivé en conditions pluviales. Le dispositif comprend quatre niveaux de Seed Priming et cinq modalités de pulvérisation foliaire, évalués à travers onze variables relatives à la croissance, au rendement et à la qualité des grains.

L'approche analytique a combiné l'exploration et la préparation des données, l'analyse descriptive et graphique, l'étude des corrélations, l'application de tests d'hypothèses ainsi qu'une Analyse en Composantes Principales (ACP). Les résultats ont révélé une forte corrélation positive entre la hauteur des plantes et le rendement en grains ($r = 0,881$; $p < 0,001$), ainsi qu'une corrélation particulièrement élevée entre le rendement en grains et le rendement protéique ($r = 0,988$; $p < 0,001$). Malgré une tendance à l'augmentation du rendement avec l'intensification du Seed Priming, l'ANOVA n'a pas mis en évidence d'effet significatif de ce facteur sur le rendement en grains ($F = 1,873$; $p = 0,141$). Le test du Khi-deux a également confirmé l'indépendance entre le Seed Priming et les traitements foliaires ($\chi^2 = 0$; $p = 1,000$). Sur le plan descriptif, les traitements foliaires nanoparticulaires ont été associés à de meilleures performances de rendement, avec Nano Mn présentant les valeurs les plus élevées. Enfin, l'ACP a permis de synthétiser la variabilité du jeu de données et de mettre en évidence les principales associations entre les caractères agronomiques. Ces résultats illustrent l'intérêt de Python et des méthodes statistiques multivariées pour l'exploitation et l'interprétation des données agronomiques et pour l'évaluation comparative des stratégies d'amélioration des performances du blé.

Mots-clés : *Triticum aestivum* L., Seed Priming, Pulvérisation foliaire, Analyse de données, Python.

1. Introduction

Le blé tendre (*Triticum aestivum* L.) est l'une des principales cultures céréalières au monde et constitue une ressource essentielle pour la sécurité alimentaire mondiale. Cependant, sa production est fortement affectée par différents stress abiotiques, notamment la salinité, la sécheresse, les températures extrêmes et la contamination des sols par les métaux lourds. Ces contraintes environnementales perturbent les processus physiologiques, biochimiques et métaboliques des plantes, entraînant une diminution de la germination, de la croissance, du développement et du rendement des cultures (Munns & Tester, 2008 ; Farooq et al., 2011 ; Hasanuzzaman et al., 2021). Par ailleurs, la croissance démographique, la réduction des terres arables et les effets du changement climatique renforcent la nécessité de développer des stratégies agricoles durables permettant de maintenir la productivité des cultures dans des conditions environnementales défavorables (Mishra et al., 2023).

Parmi les différents stress abiotiques, la salinité des sols représente l'une des principales menaces pour l'agriculture mondiale. Une concentration élevée en sels réduit la disponibilité de l'eau pour les plantes, provoque une toxicité ionique et favorise une accumulation excessive d'espèces réactives de l'oxygène (ROS). Ces perturbations entraînent une diminution de la photosynthèse, une altération des membranes cellulaires, une dégradation des protéines ainsi qu'une réduction de la croissance et du rendement des plantes (Bhagat et al., 2021 ; Hasanuzzaman et al., 2021).

Afin d'améliorer la tolérance des plantes à ces contraintes, plusieurs approches ont été développées, telles que l'amélioration génétique, la sélection variétale et l'utilisation de régulateurs de croissance. Plus récemment, les biostimulants d'origine végétale ont suscité un intérêt croissant en raison de leur caractère naturel et respectueux de l'environnement. Les extraits de plantes sont riches en composés bioactifs, notamment en composés phénoliques, flavonoïdes et terpènes, capables de stimuler les systèmes de défense antioxydants, de réguler différents mécanismes physiologiques et d'améliorer la capacité des plantes à résister aux stress abiotiques (Parvin et al., 2022 ; Kumar et al., 2023). De nombreuses études ont ainsi montré leur efficacité pour améliorer la germination des graines, la croissance végétative et le rendement des cultures dans des conditions de stress (Han et al., 2024).

L'étude de ces stratégies génère d'importants volumes de données expérimentales comprenant de nombreuses variables agronomiques et physiologiques. L'exploitation de ces données nécessite des outils performants permettant leur traitement, leur visualisation et leur

interprétation. Dans ce contexte, le langage Python s'est imposé comme l'un des principaux outils d'analyse de données grâce à ses nombreuses bibliothèques spécialisées, telles que Pandas pour la manipulation des données, NumPy pour les calculs numériques, Matplotlib et Seaborn pour les représentations graphiques, SciPy et Statsmodels pour les analyses statistiques, ainsi que Scikit-learn pour les méthodes d'analyse multivariée comme l'Analyse en Composantes Principales (ACP).

Le jeu de données étudié dans ce projet porte sur l'évaluation de différents traitements de Seed Priming (prétraitement des semences) et de Foliar Sprays (pulvérisations foliaires) appliqués au blé tendre. Les performances des traitements sont évaluées à travers plusieurs caractères agronomiques, notamment l'émergence des épis, la hauteur des plantes, le nombre de graines par épi, le rendement en grains, le rendement biologique, la teneur en protéines et l'indice de récolte.

L'objectif de ce projet est d'appliquer une démarche complète d'analyse de données sous Python à ce jeu de données agronomiques. Cette démarche comprend l'exploration et le nettoyage des données, l'analyse descriptive, la visualisation graphique, l'étude des relations entre les variables, l'application de tests statistiques ainsi que la réalisation d'une Analyse en Composantes Principales (ACP). L'ensemble de ces analyses permettra de mieux comprendre les relations existantes entre les différents caractères agronomiques, d'évaluer l'effet des traitements étudiés et de mettre en évidence les principaux facteurs expliquant la variabilité observée.

2. Présentation du dataset

Le choix du jeu de données constitue une étape essentielle dans tout projet d'analyse de données, puisqu'il détermine les méthodes statistiques pouvant être appliquées ainsi que la pertinence des résultats obtenus. Dans le cadre de ce projet, un jeu de données agronomiques portant sur le blé tendre a été sélectionné à partir de la plateforme Kaggle, une plateforme largement utilisée pour le partage de jeux de données scientifiques destinés à la recherche, à l'enseignement et au développement d'applications en science des données.

Le jeu de données utilisé est intitulé « **Seed Priming and Biostimulant in Rainfed Wheat** ». Il est disponible publiquement sur Kaggle à l'adresse suivante :

<https://www.kaggle.com/datasets/bardiatalebian/rainfedwheat>

Ce jeu de données provient d'une expérimentation conduite dans le nord-ouest de l'Iran afin d'évaluer l'effet du Seed Priming au sulfate de zinc (ZnSO_4) et de différentes pulvérisations foliaires de micronutriments (fer, zinc et manganèse) sous leurs formes conventionnelles, magnétisées et nanoparticulaires sur la croissance, le rendement et la teneur en protéines du blé cultivé en conditions pluviales (*rainfed wheat*). L'expérimentation a été réalisée selon un dispositif factoriel en blocs complètement randomisés avec quatre répétitions.

Le jeu de données comprend deux facteurs expérimentaux correspondant aux traitements appliqués :

- **A** : Seed Priming, comportant quatre niveaux (Control, 0.1 %, 0.2 % et 0.3 % de ZnSO_4).
- **B** : Foliar Sprays, comprenant cinq modalités de pulvérisation foliaire (Conventional, Magnetic, Nano Fe, Nano Zn et Nano Mn).

Les effets de ces traitements ont été évalués à travers onze variables quantitatives décrivant différents caractères agronomiques du blé, notamment l'émergence des épis, le temps jusqu'à la récolte, la hauteur des plantes, la densité des épis, le nombre de graines par épi, le poids de mille grains, le rendement en grains, le rendement biologique, la teneur en protéines, le rendement protéique et l'indice de récolte. Le tableau ci-dessous présente la signification des différentes variables étudiées.

Table 1. Description des variables du jeu de données.

Variable	Signification	Type
A	Seed Priming	Qualitative
B	Foliar Sprays	Qualitative
X1	Spike Emergence	Quantitative
X2	Days to Harvest	Quantitative
X3	Plant Height	Quantitative
X4	Spike Density	Quantitative
X5	Seeds per Spike	Quantitative
X6	Thousand Seed Weight	Quantitative
X7	Seed Yield	Quantitative
X8	Biological Yield	Quantitative
X9	Protein (%)	Quantitative
X10	Protein Yield	Quantitative
X11	Harvest Index	Quantitative

Ce jeu de données a été retenu pour plusieurs raisons. Premièrement, il associe des variables qualitatives (facteurs expérimentaux) et quantitatives (caractères agronomiques), ce qui permet d'appliquer un large éventail de méthodes d'analyse de données. Deuxièmement, il traite d'une problématique actuelle en agriculture, à savoir l'amélioration des performances du blé par des techniques de Seed Priming et l'utilisation de biostimulants. Enfin, sa structure est particulièrement adaptée aux objectifs de ce projet, puisqu'elle permet de mettre en œuvre l'ensemble des étapes d'une analyse de données sous Python, notamment l'exploration et le nettoyage des données, l'analyse descriptive, l'étude des relations entre variables, l'application de tests statistiques ainsi que la réalisation d'une Analyse en Composantes Principales (ACP).

3. Questions d'analyse

Ce projet vise à exploiter un jeu de données agronomiques afin d'évaluer l'effet de différents traitements de Seed Priming et de Foliar Sprays sur plusieurs caractères de croissance, de rendement et de qualité du blé. Les analyses réalisées ont pour objectif de répondre aux questions suivantes :

1. Quelle est la structure générale du jeu de données ?

Identifier les variables qualitatives et quantitatives, vérifier la qualité des données et explorer leur distribution.

2. Comment se répartissent les différents caractères agronomiques du blé ?

Décrire les principales caractéristiques statistiques des variables étudiées (moyenne, médiane, dispersion, valeurs extrêmes) et visualiser leur distribution à l'aide d'histogrammes et de boîtes à moustaches.

3. Existe-t-il des relations entre les différents caractères agronomiques ?

Étudier les corrélations entre les variables quantitatives afin d'identifier les paramètres les plus fortement associés, notamment entre la hauteur des plantes, le rendement en grains et le rendement protéique.

4. Le traitement de Seed Priming influence-t-il significativement le rendement en grains ?

Vérifier, à l'aide d'une analyse de variance (ANOVA), si les différents niveaux de prétraitement des semences entraînent des différences significatives du rendement en grains.

5. Existe-t-il une association entre les facteurs expérimentaux "Seed Priming" et "Foliar Sprays" ?

Évaluer cette relation à l'aide d'un test du Khi-deux d'indépendance.

6. Peut-on résumer l'information contenue dans les variables agronomiques par un nombre réduit de composantes ?

Utiliser l'Analyse en Composantes Principales (ACP) afin d'identifier les principales sources de variabilité du jeu de données et de visualiser les relations entre les variables.

7. Quels traitements semblent les plus favorables à l'amélioration des performances agronomiques du blé ?

Interpréter l'ensemble des résultats statistiques afin de mettre en évidence les traitements associés aux meilleures performances en termes de croissance, de rendement et de qualité.

4. Méthodologie

L'analyse des données a été réalisée à l'aide du langage de programmation Python, en utilisant L'analyse des données a été réalisée à l'aide du langage de programmation Python en utilisant la plateforme Google Colab, un environnement interactif basé sur le cloud permettant d'exécuter du code Python sans installation préalable. Plusieurs bibliothèques spécialisées ont été utilisées pour le traitement, la visualisation et l'analyse statistique des données (Tableau 2).

Table 2. Bibliothèques Python utilisées.

Bibliothèque	Fonction
Pandas	Importation et manipulation des données
NumPy	Calculs numériques
Matplotlib	Création de graphiques
Seaborn	Visualisation statistique
SciPy	Tests statistiques
Statsmodels	Analyse de variance (ANOVA)
Scikit-learn	Analyse en Composantes Principales (ACP)

L'analyse s'est déroulée selon les étapes suivantes : chargement et exploration des données, préparation du jeu de données, analyse descriptive, étude des relations entre les variables, réalisation des tests statistiques et Analyse en Composantes Principales (ACP).

4.1. Chargement et exploration des données

Le jeu de données « Seed Priming and Biostimulant in Rainfed Wheat », téléchargé depuis la plateforme Kaggle, a été importé dans Google Colab au format CSV à l'aide de la bibliothèque Pandas (read_csv()).

Une première exploration du jeu de données a ensuite été réalisée afin de vérifier que l'importation s'était déroulée correctement et d'obtenir une vue d'ensemble des données. Cette étape a consisté à :

- Afficher les premières lignes du tableau (head()).
- Déterminer les dimensions du jeu de données (shape).
- Identifier les variables et leur type (info()).
- Obtenir des statistiques descriptives préliminaires (describe()).

```
df=pd.read_csv("x11.csv")
df.head(4)
```

[3] ✓ 0.0s Python

	A	B	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11
0	1	1	153	171	78.6	256	36	38.3	1372	4027	9.3	127.596	34.070027
1	1	2	150	173	79.7	267	39	39.7	1389	4065	9.5	131.955	34.169742
2	1	3	148	176	82.5	288	45	40.6	1526	4280	11.1	169.386	35.654206
3	1	4	145	180	83.1	291	48	41.2	1559	4347	11.4	177.726	35.863814

```
df.shape
```

(80, 13)

```
nombre_observations = df.shape[0]
nombre_variables = df.shape[1]
print("Nombre d'observations :", nombre_observations)
print("Nombre de variables :", nombre_variables)
```

Nombre d'observations : 80
Nombre de variables : 13

Python

```
df.info()
```

[9] Python

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 80 entries, 0 to 79
Data columns (total 13 columns):
#   Column  Non-Null Count  Dtype
---  -
0    A      80 non-null       category
1    B      80 non-null       category
2    X1      80 non-null       int64
3    X2      80 non-null       int64
4    X3      80 non-null       float64
5    X4      80 non-null       int64
6    X5      80 non-null       int64
7    X6      80 non-null       float64
8    X7      80 non-null       int64
9    X8      80 non-null       int64
10   X9      80 non-null       float64
11   X10     80 non-null       float64
12   X11     80 non-null       float64
dtypes: category(2), float64(5), int64(6)
memory usage: 7.6 KB
```

[11] `df.describe().T` Python

	count	mean	std	min	25%	50%	75%	max
X1	80.0	143.187500	5.021709	133.000000	139.750000	143.000000	147.000000	155.000000
X2	80.0	182.987500	6.032599	169.000000	179.000000	183.500000	188.000000	194.000000
X3	80.0	83.537500	2.508536	77.700000	82.050000	83.450000	85.100000	90.100000
X4	80.0	289.937500	17.836347	251.000000	275.000000	292.000000	302.250000	322.000000
X5	80.0	47.975000	7.898045	33.000000	41.000000	48.000000	55.000000	62.000000
X6	80.0	42.328750	1.758681	38.100000	41.200000	42.450000	43.900000	44.900000
X7	80.0	1523.112500	95.061338	1368.000000	1424.250000	1562.500000	1601.250000	1660.000000
X8	80.0	4751.425000	3928.466525	4005.000000	4143.500000	4377.000000	4427.000000	39412.000000
X9	80.0	10.847500	0.963771	9.100000	9.800000	11.300000	11.600000	12.300000
X10	80.0	166.091838	24.416722	124.488000	139.383000	180.565000	185.512750	200.613000
X11	80.0	34.951995	3.869245	3.577591	34.47369	35.869695	36.296163	37.228078

Cette exploration permet de comprendre la structure générale du jeu de données avant de procéder à son traitement.

4.2. Nettoyage et préparation des données

Après l'exploration initiale, plusieurs contrôles ont été réalisés afin de garantir la qualité des données avant les analyses statistiques.

Les opérations effectuées sont les suivantes :

- Vérification de la présence de valeurs manquantes à l'aide de la fonction `isnull().sum()`.
- Recherche d'éventuels doublons avec la fonction `uplicated().sum()`.
- Conversion des variables Seed Priming (A) et Foliar Sprays (B) en variables catégorielles afin de faciliter les analyses statistiques.
- Contrôle des types de variables.

```

valeurs_manquantes = df.isnull().sum()
pourcentage_manquant = (df.isnull().sum() / len(df)) * 100

tableau_manquants = pd.DataFrame({
    "Valeurs manquantes": valeurs_manquantes,
    "Pourcentage (%)": pourcentage_manquant.round(2)
})

tableau_manquants = tableau_manquants[tableau_manquants["Valeurs manquantes"] > 0]

tableau_manquants

```

Python

Valeurs manquantes	Pourcentage (%)
--------------------	-----------------

```

nombre_doublons = df.duplicated().sum()
print("Nombre de lignes dupliquées :", nombre_doublons)
index_doublons = df[df.duplicated()].index.tolist()
print("Index des lignes dupliquées :")
print(index_doublons)
df_doublons = df[df.duplicated()]
df_doublons

```

Python

Nombre de lignes dupliquées : 0
Index des lignes dupliquées :
[]

A	B	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11
---	---	----	----	----	----	----	----	----	----	----	-----	-----

```
df[["A", "B"]] = df[["A", "B"]].astype("category")
```

Python

```
variables_numeriques = df.select_dtypes(include=["int64", "float64"]).columns.tolist()
variables_categorielles = df.select_dtypes(include=["object", "category", "bool"]).columns.tolist()
variables_temporelles = df.select_dtypes(include=["datetime64"]).columns.tolist()
print("Variables numériques :")
for col in variables_numeriques:
    print("-", col)

print("\nVariables catégorielles :")
for col in variables_categorielles:
    print("-", col)

print("\nVariables temporelles :")
for col in variables_temporelles:
    print("-", col)
```

Python

Variables numériques :

- X1
- X2
- X3
- X4
- X5
- X6
- X7
- X8
- X9
- X10
- X11

Variables catégorielles :

- A
- B

```
- Le jeu de données contient 80 observations et 13 variables.
- 11 variable(s) numérique(s) ont été détectée(s).
- 2 variable(s) catégorielle(s) ont été détectée(s).
  !!! Remarque : une vérification des types est nécessaire.
    -> Le type détecté automatiquement peut être incorrect :
      - une date peut être importée comme variable objet ;
      - une variable numérique peut être importée comme variable objet ;
      - une variable qualitative peut être codée sous forme numérique.
- Aucune valeur manquante n'a été détectée.
- Aucun doublon n'a été détecté.
```

Ces étapes permettent d'obtenir un jeu de données cohérent et prêt à être utilisé pour les analyses descriptives et inférentielles.

4.3. Analyse descriptive et visualisation adaptée

L'analyse descriptive a été réalisée afin d'obtenir une vue d'ensemble du jeu de données et de caractériser les variables étudiées avant la mise en œuvre des analyses statistiques.

Dans un premier temps, les variables du jeu de données ont été organisées selon leur nature et leur rôle dans l'étude. Elles ont été réparties en quatre groupes : les traitements expérimentaux (Seed Priming et Foliar Spray), les variables liées à la croissance et au développement des plantes, les composantes du rendement et les variables décrivant la qualité du grain. Cette classification facilite l'interprétation des résultats et la planification des analyses ultérieures.

```

Traitements :
- Seed Priming (A)
- Foliar Spray (B)

Croissance et développement :
- Spike Emergence (X1)
- Days to Harvest (X2)
- Plant Height (X3)

Composantes du rendement :
- Spike Density (X4)
- Seeds per Spike (X5)
- Thousand Seed Weight (X6)
- Seed Yield (X7)
- Biological Yield (X8)

Qualité du grain :
- Protein Percentage (X9)
- Protein Yield (X10)
- Harvest Index (X11)

```

Ensuite, les variables quantitatives ont fait l'objet d'une analyse descriptive à l'aide de la fonction `describe()`. Cette analyse a permis de calculer, pour chacune des onze variables numériques, le nombre d'observations, la moyenne, l'écart-type, les valeurs minimale et maximale ainsi que les quartiles (25 %, 50 % et 75 %). Un tableau récapitulatif présentant les valeurs minimales, maximales et les moyennes de chaque variable a également été généré afin de fournir une synthèse des principales caractéristiques du jeu de données.

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11
count	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000	80.000000
mean	143.187500	182.987500	83.537500	289.937500	47.975000	42.328750	1523.112500	4751.425000	10.847500	166.091838	34.951995
std	5.021709	6.032599	2.508536	17.836347	7.898045	1.758681	95.061338	3928.466525	0.963771	24.416722	3.869245
min	133.000000	169.000000	77.700000	251.000000	33.000000	38.100000	1368.000000	4005.000000	9.100000	124.488000	3.577591
25%	139.750000	179.000000	82.050000	275.000000	41.000000	41.200000	1424.250000	4143.500000	9.800000	139.383000	34.473690
50%	143.000000	183.500000	83.450000	292.000000	48.000000	42.450000	1562.500000	4377.000000	11.300000	180.565000	35.869695
75%	147.000000	188.000000	85.100000	302.250000	55.000000	43.900000	1601.250000	4427.000000	11.600000	185.512750	36.296163
max	155.000000	194.000000	90.100000	322.000000	62.000000	44.900000	1660.000000	39412.000000	12.300000	200.613000	37.228078

Le tableau des statistiques descriptives présente les principaux indicateurs de tendance centrale et de dispersion des onze variables quantitatives du jeu de données. L'ensemble des variables comporte 80 observations, ce qui confirme que le jeu de données est complet pour toutes les variables quantitatives étudiées. Les variables liées au développement de la culture présentent une variabilité relativement faible. L'émergence des épis (X1) est observée en moyenne 143,19 jours après le semis, avec des valeurs comprises entre 133 et 155 jours et un faible écart-type (5,02 jours). De même, le temps nécessaire pour atteindre la récolte (X2) est relativement homogène, avec une moyenne de 182,99 jours, une médiane de 183,50 jours et un écart-type de 6,03 jours, indiquant une faible dispersion entre les observations. Concernant les caractères morphologiques, la hauteur des plantes (X3) présente une moyenne de 83,54 cm, avec une faible dispersion (écart-type = 2,51 cm). La densité d'épis (X4) atteint en moyenne 289,94 épis m⁻², tandis que le nombre moyen de graines par épi (X5) est de 47,98 graines. Le poids de mille grains (X6) est relativement stable, avec une moyenne de 42,33 g et un faible écart-type (1,76 g), traduisant une bonne homogénéité de cette composante du rendement. Les variables

relatives au rendement montrent une variabilité plus importante. Le rendement en grains (X7) est compris entre 1368 et 1660 kg.ha⁻¹, avec une moyenne de 1523,11 kg.ha⁻¹. En revanche, le rendement biologique (X8) présente une très forte dispersion (écart-type = 3928,47 kg.ha⁻¹) et une différence importante entre la moyenne (4751,42 kg.ha⁻¹) et la médiane (4377 kg.ha⁻¹), ce qui suggère la présence de valeurs exceptionnellement élevées. Les variables décrivant la qualité du grain présentent également une dispersion modérée. La teneur moyenne en protéines (X9) est de 10,85 %, tandis que le rendement protéique (X10) atteint en moyenne 166,09 kg ha⁻¹. Enfin, l'indice de récolte (X11) présente une moyenne de 34,95 %, mais une valeur minimale particulièrement faible (3,58 %), susceptible d'influencer la distribution de cette variable. Dans l'ensemble, la proximité entre la moyenne et la médiane pour la majorité des variables indique des distributions relativement équilibrées. En revanche, les variables X8 (Biological Yield) et X11 (Harvest Index) présentent des écarts plus importants entre ces deux indicateurs, laissant supposer une asymétrie de leur distribution et la présence de valeurs atypiques, qui seront examinées plus en détail à l'aide des représentations graphiques.

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11
Minimum	133.00	169.00	77.70	251.00	33.00	38.10	1368.00	4005.00	9.10	124.49	3.58
Maximum	155.00	194.00	90.10	322.00	62.00	44.90	1660.00	39412.00	12.30	200.61	37.23
Moyenne	143.19	182.99	83.54	289.94	47.98	42.33	1523.11	4751.42	10.85	166.09	34.95

Le tableau récapitulatif met en évidence l'amplitude des valeurs observées pour chacune des variables étudiées. Les variables X1 à X6 présentent des intervalles relativement restreints, traduisant une faible variabilité entre les observations. Les valeurs minimales et maximales restent proches des moyennes, ce qui confirme l'homogénéité des données pour les caractères de croissance et les principales composantes du rendement. Le rendement en grains (X7) varie de 1368 à 1660 kg.ha⁻¹, illustrant une variabilité modérée entre les traitements expérimentaux. En revanche, le rendement biologique (X8) présente une amplitude très importante, avec des valeurs comprises entre 4005 et 39 412 kg.ha⁻¹. Cette différence considérable confirme la présence d'observations extrêmes, déjà suggérée par les statistiques descriptives. Les variables relatives à la qualité du grain (X9, X10 et X11) montrent des amplitudes plus faibles, à l'exception de X11, dont la valeur minimale (3,58 %) est très éloignée de la moyenne (34,95 %), indiquant la présence probable de valeurs atypiques. Globalement, ces résultats montrent que la majorité des variables présentent une dispersion limitée, tandis que X8 et X11 se distinguent par une variabilité plus importante. Ces observations justifient l'utilisation des histogrammes et des boîtes à moustaches afin d'examiner plus précisément la distribution des données et d'identifier les éventuelles valeurs aberrantes.

Les variables qualitatives correspondant aux facteurs expérimentaux Seed Priming (A) et Foliar Spray (B) ont ensuite été décrites en déterminant le nombre de catégories ainsi que les effectifs associés à chacune d'elles à l'aide de la fonction `value_counts()`. Cette étape a permis de vérifier la répartition des observations entre les différents traitements.

```
Variable : A
Nombre de catégories différentes : 4

  count
A
1     20
2     20
3     20
4     20

dtype: int64

Variable : B
Nombre de catégories différentes : 5

  count
B
1     16
2     16
3     16
4     16
5     16

dtype: int64
```

Les variables qualitatives du jeu de données correspondent aux deux facteurs expérimentaux étudiés, à savoir le Seed Priming (A) et les Foliar Sprays (B). La variable A (Seed Priming) comporte quatre catégories, correspondant aux différents niveaux de prétraitement des semences (Control, 0,1 %, 0,2 % et 0,3 %). Chacune de ces modalités est représentée par 20 observations, soit un total de 80 observations. Cette répartition parfaitement équilibrée garantit une représentation identique de chaque traitement dans le jeu de données et facilite les comparaisons statistiques entre les différentes modalités. La variable B (Foliar Sprays) comprend cinq catégories, correspondant aux cinq types de pulvérisations foliaires (Conventional, Magnetic, Nano Fe, Nano Zn et Nano Mn). Chaque modalité est représentée par 16 observations, soit également un total de 80 observations. Cette distribution homogène assure une représentation équivalente de l'ensemble des traitements foliaires. Ainsi, les deux facteurs expérimentaux présentent une répartition équilibrée des observations entre leurs différentes modalités. Cette homogénéité constitue un avantage pour les analyses statistiques ultérieures, notamment l'analyse de variance (ANOVA) et les comparaisons entre traitements, en limitant les biais liés à un déséquilibre des effectifs.

Enfin, une synthèse de l'exploration descriptive a été réalisée afin de rappeler le nombre de variables qualitatives et quantitatives disponibles ainsi que leur organisation en différentes dimensions d'analyse. Cette synthèse constitue une base pour les étapes suivantes du projet, notamment les analyses de corrélation, les tests statistiques et l'Analyse en Composantes Principales (ACP).

```
=====
Premières pistes d'analyse
=====
- Les variables A (Seed Priming) et B (Foliar Spray) permettront d'étudier l'effet des traitements appliqués au blé.
- Les variables X1, X2 et X3 permettront d'analyser la croissance et le développement des plantes.
- Les variables X4, X5, X6, X7 et X8 permettront d'étudier les composantes du rendement.
- Les variables X9, X10 et X11 permettront d'évaluer la qualité du grain et les performances agronomiques.
- Les variables quantitatives pourront être utilisées pour les statistiques descriptives et les analyses de corrélation.
- Les variables A et B serviront aux comparaisons entre traitements (ANOVA, tests post-hoc, etc.).
- L'ensemble des variables quantitatives pourra être utilisé pour une Analyse en Composantes Principales (ACP).

=====
Synthèse de l'exploration ciblée
=====
- Nombre de variables quantitatives : 11
- Nombre de variables qualitatives : 2

Dimensions principales disponibles :


Traitements (2 variables) :
- Seed Priming (A)
- Foliar Spray (B)

Croissance et développement (3 variables) :
...


Conclusion :
Le jeu de données est organisé autour de deux facteurs expérimentaux (Seed Priming et Foliar Spray) et de onze variables agronomiques.
Cette organisation permettra de réaliser des statistiques descriptives, des visualisations, des analyses de corrélation, des comparaisons entre traitem
```

✓ Histogrammes


Afin de compléter l'analyse descriptive, plusieurs représentations graphiques ont été réalisées pour explorer la distribution des données et faciliter leur interprétation. Dans un premier temps, des histogrammes ont été construits pour chacune des variables quantitatives afin d'observer leur distribution et d'apprécier la répartition des observations. Ces graphiques permettent d'identifier la forme générale des distributions ainsi que la dispersion des valeurs.




L'histogramme de X1 (Spike Emergence) montre une distribution relativement symétrique, avec une forte concentration des observations entre 140 et 147 jours après semis. La moyenne (143,19 jours) est très proche de la médiane (143 jours), ce qui confirme une distribution globalement équilibrée. L'étendue est limitée (133 à 155 jours), traduisant une faible variabilité de l'émergence des épis entre les différents traitements. Aucun point extrême n'est observé, ce qui témoigne d'une bonne homogénéité des données.




La variable X2 (Days to Harvest) présente une distribution relativement homogène, avec la majorité des observations comprises entre 179 et 190 jours. La proximité entre la moyenne (182,99 jours) et la médiane (183,50 jours) indique une faible asymétrie de la distribution. La faible dispersion observée suggère que les différents traitements ont peu modifié la durée totale du cycle cultural jusqu'à la récolte.




L'histogramme de X3 (Plant Height) indique que la majorité des plantes présentent une hauteur comprise entre 82 et 86 cm, avec un maximum de fréquence autour de 83-84 cm. La moyenne (83,54 cm) est très proche de la médiane (83,45 cm), traduisant une distribution quasi symétrique. Une valeur légèrement plus élevée, proche de 90 cm, est visible et correspond à la valeur aberrante détectée lors de l'analyse descriptive. Toutefois, cette observation reste isolée et n'affecte pas significativement la distribution générale.




La variable X4 (Spike Density) présente une distribution relativement étendue, avec des valeurs comprises entre 251 et 322 épis.m⁻². La majorité des observations est concentrée entre 285 et 305 épis.m⁻². La proximité entre la moyenne (289,94 épis.m⁻²) et la médiane (292 épis.m⁻²) indique une distribution équilibrée, sans présence de valeurs extrêmes importantes.




L'histogramme de X5 (Seeds per Spike) montre une répartition relativement homogène des observations entre 33 et 62 graines par épi. La moyenne (47,98 graines) est pratiquement identique à la médiane (48 graines), traduisant une distribution symétrique. Aucune concentration excessive ni valeur aberrante n'est observée, ce qui suggère une variabilité normale de cette composante du rendement.




La distribution de X6 (Thousand Seed Weight) est relativement resserrée autour de 42 à 44 g, avec une moyenne de 42,33 g et un faible écart-type (1,76 g). Cette faible dispersion traduit une bonne homogénéité du poids de mille grains entre les observations. Aucun point atypique n'est mis en évidence.




La variable X7 (Seed Yield) présente une distribution plus hétérogène que les variables précédentes. Deux groupes principaux d'observations apparaissent, l'un situé autour de 1380-1450 kg.ha⁻¹ et l'autre entre 1570 et 1630 kg.ha⁻¹, donnant à l'histogramme une allure bimodale. Cette répartition est probablement liée aux différents traitements de Seed Priming et de Foliar Spray, qui influencent le rendement en grains. Malgré cette variabilité, aucune valeur aberrante n'a été détectée.




L'histogramme de X8 (Biological Yield) met clairement en évidence une forte asymétrie à droite. La quasi-totalité des observations est comprise entre 4000 et 4500 kg.ha⁻¹, tandis qu'une valeur extrêmement élevée, proche de 39400 kg.ha⁻¹, apparaît isolée. Cette observation correspond aux trois valeurs aberrantes identifiées lors de l'analyse descriptive et explique l'écart important entre la moyenne (4751,42 kg.ha⁻¹) et la médiane (4377 kg.ha⁻¹), ainsi que le très fort écart-type observé. Cette variable devra être interprétée avec prudence.



La distribution de X9 (Protein Percentage) montre que la majorité des observations se situe entre 11 et 12 %, avec un second groupe de valeurs compris entre 9,5 et 10 %. Cette légère bimodalité suggère une influence des traitements expérimentaux sur la teneur en protéines des grains. Malgré cette répartition, aucune valeur aberrante n'a été détectée et la dispersion reste modérée.



L'histogramme de X10 (Protein Yield) présente également une distribution bimodale, avec un premier groupe d'observations autour de 130-145 kg.ha⁻¹ et un second autour de 180-190 kg.ha⁻¹. Cette distribution reflète probablement les différences de rendement protéique entre les traitements étudiés. Bien que la moyenne (166,09 kg.ha⁻¹) soit inférieure à la médiane (180,56 kg.ha⁻¹), aucune valeur aberrante n'a été identifiée.












La variable X11 (Harvest Index) présente une forte concentration des observations entre 34 et 37 %, indiquant une bonne homogénéité de l'indice de récolte pour la majorité des traitements. Cependant, deux groupes de valeurs très faibles, notamment une observation proche de 3,6 % et une autre autour de 28 %, apparaissent nettement isolés du reste des données. Ces observations correspondent aux valeurs aberrantes détectées lors de l'analyse descriptive et expliquent l'écart entre la moyenne (34,95 %) et la médiane (35,87 %). En dehors de ces valeurs atypiques, la distribution est relativement resserrée.


Dans l'ensemble, les histogrammes montrent que la plupart des variables agronomiques présentent des distributions relativement homogènes, avec une faible dispersion et peu de valeurs aberrantes. Les variables X8 (Biological Yield) et X11 (Harvest Index) se distinguent par la présence de valeurs atypiques, tandis que X7 (Seed Yield), X9 (Protein Percentage) et X10 (Protein Yield) présentent une distribution bimodale, probablement liée aux différents traitements expérimentaux appliqués (Seed Priming et Foliar Spray). Ces observations justifient la poursuite des analyses statistiques afin d'évaluer l'effet des traitements sur les différentes caractéristiques agronomiques du blé.

✓ Coubes de densité

Des courbes de densité (Kernel Density Estimation – KDE) ont également été tracées afin d'obtenir une représentation plus lissée de la distribution des variables quantitatives. Ces courbes complètent les histogrammes en mettant en évidence la concentration des observations et la forme de la distribution.








Les courbes de densité confirment les tendances observées sur les histogrammes en offrant une représentation plus lissée de la distribution des variables quantitatives. Les variables X1 à X6 présentent des distributions globalement unimodales et relativement homogènes, traduisant une faible dispersion des observations autour de leur moyenne. En revanche, les variables X7 (Seed Yield), X9 (Protein Percentage) et X10 (Protein Yield) présentent une distribution bimodale, caractérisée par deux pics de densité distincts. Cette configuration suggère l'existence de deux groupes d'observations, probablement associés aux différentes modalités des traitements Seed Priming et Foliar Spray. Les variables X8 (Biological Yield) et X11 (Harvest Index) se distinguent par une forte asymétrie de leur distribution, liée à la présence de valeurs atypiques déjà mises en évidence lors de l'analyse descriptive. Dans l'ensemble, les courbes de densité confirment la faible variabilité de la majorité des variables tout en mettant davantage en évidence les asymétries et les distributions multimodales observées dans le jeu de données.

✓ Boîtes à moustaches


Par ailleurs, des boîtes à moustaches (Boxplots) ont été réalisées pour chaque variable quantitative. Ces graphiques permettent de visualiser la dispersion des données, les quartiles, la médiane ainsi que les éventuelles valeurs aberrantes détectées au sein du jeu de données.




La boîte à moustaches de X1 montre une distribution relativement homogène des observations. La médiane est située autour de 143 jours après semis et se trouve approximativement au centre de la boîte, traduisant une distribution relativement symétrique. Les moustaches présentent une longueur comparable de part et d'autre de la médiane et aucune valeur aberrante n'est observée.




La variable X2 présente une distribution relativement équilibrée. La médiane est proche de 183 jours, tandis que les quartiles indiquent une dispersion modérée des observations. Aucun point atypique n'est mis en évidence, ce qui confirme l'absence de valeurs aberrantes.




La boîte à moustaches de X3 met en évidence une dispersion relativement faible des hauteurs de plantes, avec une médiane proche de 83,5 cm. Une valeur située aux alentours de 90 cm apparaît au-delà de la moustache supérieure, indiquant la présence d'une valeur aberrante, déjà identifiée lors de l'analyse descriptive.




La variable X4 (Spike Density) présente une distribution relativement homogène. La médiane est située autour de 292 épis.m⁻² et la dispersion entre le premier et troisième quartile est modérée. Aucune valeur aberrante n'est observée.



La boîte à moustaches de X5 montre une répartition relativement homogène des observations autour d'une médiane proche de 48 graines par épi. La dispersion est modérée et aucun point atypique n'est détecté.




La variable X6 présente une faible dispersion, avec une médiane située autour de 42,5 g. La boîte est relativement étroite, traduisant une bonne homogénéité du poids de mille grains. Aucune valeur aberrante n'est mise en évidence.




La boîte à moustaches de X7 montre une dispersion plus importante que celle observée pour les variables précédentes. La médiane est située autour de 1562 kg.ha^{-1} , tandis que l'étendue des valeurs est relativement large. Toutefois, aucune valeur aberrante n'est détectée selon le critère de l'écart interquartile.




La boîte à moustaches de X8 met clairement en évidence la présence d'une valeur extrêmement élevée, représentée par un point isolé situé autour de 39400 kg.ha^{-1} . La majorité des observations est regroupée entre 4000 et 4500 kg.ha^{-1} , ce qui traduit une faible dispersion du groupe principal. Cette valeur atypique explique la forte asymétrie observée dans les histogrammes et les courbes de densité, ainsi que le niveau élevé de l'écart-type.



La variable X9 présente une distribution relativement homogène. La médiane est proche de 11,3 %, la dispersion est modérée et aucune valeur aberrante n'est détectée. La distribution apparaît globalement équilibrée.



La boîte à moustaches de X10 montre une dispersion modérée des observations autour d'une médiane proche de 181 kg.ha⁻¹. Les moustaches sont relativement équilibrées et aucune valeur aberrante n'est observée.




La boîte à moustaches de X11 montre que la majorité des observations est concentrée entre 34 et 37 %, avec une médiane proche de 36 %. Deux points isolés apparaissent en dehors des moustaches, l'un autour de 28 % et l'autre autour de 3,6 %, confirmant la présence de deux valeurs aberrantes déjà détectées lors de l'analyse descriptive. En dehors de ces observations atypiques, la dispersion des données est relativement faible.


Les boîtes à moustaches confirment les résultats obtenus lors de l'analyse descriptive, des histogrammes et des courbes de densité. La majorité des variables (X1 à X7, X9 et X10) présentent une dispersion modérée et ne montrent pas de valeurs aberrantes. En revanche, les variables X3, X8 et X11 présentent des observations atypiques, identifiées par des points situés en dehors des moustaches. Plus précisément, une valeur aberrante est observée pour X3, une valeur extrêmement élevée est mise en évidence pour X8, tandis que X11 présente deux valeurs atypiques. Ces résultats confirment que les distributions de X8 et X11 sont les plus influencées par des observations extrêmes au sein du jeu de données.

✓ Diagrammes en barres, diagrammes circulaires et diagrammes de Pareto

Enfin, des diagrammes en barres, diagrammes circulaires et diagrammes de Pareto ont été utilisés pour représenter la répartition des variables qualitatives Seed Priming (A) et Foliar Spray (B).



La visualisation univariée de la variable A (Seed Priming) montre que les quatre modalités de traitement sont représentées de manière parfaitement équilibrée dans le jeu de données. Le diagramme en barres indique que chacune des modalités comporte 20 observations, soit 25 % de l'effectif total (80 observations). Cette répartition est confirmée par le diagramme circulaire, où chaque catégorie occupe une part identique de 25 %. Le diagramme de Pareto montre également que les effectifs sont équivalents entre les différentes modalités, ce qui se traduit par une progression régulière du pourcentage cumulé jusqu'à 100 %. Cette distribution homogène garantit un plan expérimental équilibré et constitue un avantage pour les analyses statistiques ultérieures, notamment les comparaisons entre traitements à l'aide de l'ANOVA.



La visualisation univariée de la variable B (Foliar Sprays) montre que les cinq modalités de pulvérisation foliaire sont réparties de manière uniforme dans le jeu de données. Le diagramme en barres indique que chacune des modalités est représentée par 16 observations, soit 20 % de l'effectif total. Le diagramme circulaire confirme cette répartition parfaitement équilibrée, tandis que le diagramme de Pareto met en évidence une progression régulière du pourcentage cumulé jusqu'à 100 %. Cette homogénéité des effectifs entre les différentes modalités assure une comparaison équitable entre les traitements et renforce la robustesse des analyses statistiques réalisées par la suite.


4.4. Analyse des relations entre variables

Après avoir étudié séparément la distribution de chaque variable, il est nécessaire d'examiner les relations existantes entre elles. Cette étape permet d'identifier les éventuelles associations entre les différents caractères agronomiques, d'évaluer l'influence des traitements sur les performances du blé et de déterminer quelles variables évoluent simultanément. L'analyse des relations entre variables constitue une étape importante avant la réalisation des tests statistiques et de l'Analyse en Composantes Principales (ACP), car elle met en évidence les liens susceptibles d'expliquer les variations observées au sein du jeu de données.

Dans cette étude, plusieurs approches complémentaires ont été utilisées. La relation entre la hauteur de la plante (X3) et le rendement en grains (X7) a été explorée à l'aide de nuages de points, d'une droite de régression et d'un diagramme Hexbin. Les distributions du rendement en grains selon les traitements Seed Priming (A) et Foliar Spray (B) ont ensuite été comparées au moyen de boîtes à moustaches, de diagrammes en violon ainsi que de graphiques représentant les moyennes et les médianes. Enfin, une matrice de corrélation de Pearson et sa représentation sous forme de carte thermique (heatmap) ont été réalisées afin d'évaluer l'intensité et le sens des relations entre l'ensemble des variables quantitatives.

✓ Relation entre la hauteur de la plante (X3) et le rendement en grains (X7)

L'étude des relations entre les variables quantitatives constitue une étape essentielle de l'analyse exploratoire des données. Elle permet d'identifier les éventuelles associations entre les caractères agronomiques et de mieux comprendre les facteurs susceptibles d'influencer le rendement des cultures. Dans cette partie, la relation entre la hauteur de la plante (Plant Height, X3) et le rendement en grains (Seed Yield, X7) est étudiée à l'aide de trois représentations graphiques complémentaires : un nuage de points, un nuage de points avec droite de régression et un diagramme hexagonal (Hexbin). Ces visualisations permettent d'évaluer la forme de la relation, son intensité ainsi que la répartition des observations.



Le nuage de points met en évidence une relation positive entre la hauteur de la plante (X3) et le rendement en grains (X7). Les observations suivent une tendance ascendante : lorsque la hauteur des plantes augmente, le rendement en grains tend également à augmenter. Les valeurs les plus faibles du rendement (environ 1368 à 1450 kg.ha⁻¹) sont principalement observées pour des hauteurs comprises entre 78 et 82 cm, tandis que les rendements les plus élevés (1600 à 1660 kg.ha⁻¹) correspondent à des plantes mesurant environ 85 à 90 cm.

Le graphique intégrant une droite de régression linéaire confirme cette relation croissante. La pente positive de la droite indique qu'une augmentation de la hauteur de la plante est associée à une augmentation du rendement en grains. Par ailleurs, la majorité des observations est relativement proche de la droite de régression, ce qui traduit une relation linéaire importante entre ces deux variables. La bande de confiance entourant la droite reste relativement étroite, suggérant une bonne précision de l'estimation.

Le diagramme Hexbin apporte une information supplémentaire en représentant la densité des observations. Les hexagones les plus foncés correspondent aux zones où les données sont les plus concentrées. La plus forte densité est observée pour des hauteurs comprises entre 83 et 85 cm et des rendements compris entre 1560 et 1600 kg.ha⁻¹, indiquant que cette combinaison de valeurs est la plus fréquente dans le jeu de données.

L'ensemble de ces représentations met donc en évidence une forte association positive entre la hauteur de la plante et le rendement en grains. Cette observation est confirmée par le coefficient de corrélation de Pearson calculé entre ces deux variables ($r = 0,881$), qui traduit une corrélation positive forte. Ainsi, dans les conditions expérimentales de cette étude, les plantes les plus hautes sont généralement associées à des rendements en grains plus élevés. Toutefois, cette relation traduit une association statistique et ne permet pas, à elle seule, de conclure à un lien de causalité entre les deux variables.

```
correlation_x3_x7 = df["X3"].corr(df["X7"])
print("Corrélation entre X3 et X7 :", correlation_x3_x7)
```


Corrélation entre X3 et X7 : 0.8813265191315895

Python

✓ Influence du traitement A (Seed Priming) et B (Foliar Spray) sur le rendement en grains

Afin d'évaluer l'influence des traitements de Seed Priming (A) et de Foliar Spray (B) sur le rendement en grains (X7), plusieurs représentations graphiques ont été réalisées. Les boîtes à moustaches (boxplots) et les diagrammes en violon (violin plots) permettent d'étudier la

distribution et la variabilité du rendement pour chaque modalité des deux facteurs, tandis que les graphiques des moyennes et des médianes mettent en évidence les tendances générales observées entre les différents traitements. Cette analyse descriptive permet d'identifier les effets potentiels des traitements sur le rendement en grains avant leur validation par des tests statistiques appropriés.




Les boîtes à moustaches montrent une augmentation progressive du rendement en grains lorsque l'on passe du traitement A1 (Control) au traitement A4 (0,3 % ZnSO_4). Les médianes augmentent régulièrement d'une modalité à l'autre (A1 : Control ; A2 : 0,1 % ZnSO_4 ; A3 : 0,2 % ZnSO_4 ; A4 : 0,3 % ZnSO_4), ce qui suggère une amélioration du rendement associée à l'augmentation de la concentration en sulfate de zinc utilisée pour le préconditionnement des semences. Les rendements les plus élevés sont observés avec le traitement A4, tandis que le traitement A1 présente les valeurs les plus faibles.

Les diagrammes en violon confirment cette tendance. Ils montrent que la distribution des rendements se déplace progressivement vers des valeurs plus élevées du traitement A1 au traitement A4. La forme relativement similaire des violons indique que la dispersion des données reste globalement comparable entre les différents traitements, bien que quelques différences de densité soient observées.

Les graphiques représentant les moyennes et les médianes mettent également en évidence une augmentation régulière du rendement moyen et médian entre les traitements A1, A2, A3 et A4. Cette évolution traduit une tendance positive entre l'intensité du traitement de Seed Priming et le rendement obtenu.

Dans l'ensemble, ces représentations suggèrent que le Seed Priming exerce un effet favorable sur le rendement en grains du blé. Parmi les modalités étudiées, le traitement A4 (0,3 % ZnSO_4) semble associé aux meilleures performances, tandis que le traitement A1 (Control) présente les rendements les plus faibles.



Les boîtes à moustaches mettent en évidence des différences marquées du rendement en grains (X7) selon les modalités du traitement B. Les traitements B1 (Conventional) et B2 (Magnetic) présentent les médianes les plus faibles, avec des rendements principalement compris entre 1370 et 1450 $\text{kg} \cdot \text{ha}^{-1}$. En revanche, les traitements utilisant des pulvérisations foliaires sous forme de nanoparticules (B3 : Nano Fe ; B4 : Nano Zn ; B5 : Nano Mn) affichent un net déplacement de la distribution vers des valeurs plus élevées, avec des médianes proches ou supérieures à 1600 $\text{kg} \cdot \text{ha}^{-1}$. Parmi ces traitements, B5 (Nano Mn) présente la médiane la plus élevée, suivi de B4 (Nano Zn) puis B3 (Nano Fe).


Les diagrammes en violon confirment cette tendance. Les distributions des traitements B1 et B2 sont concentrées autour de faibles valeurs de rendement, tandis que celles des traitements B3, B4 et B5 sont décalées vers les rendements les plus élevés. Les formes relativement compactes des violons indiquent une dispersion modérée des observations au sein de chaque traitement, tout en montrant une nette séparation entre les traitements conventionnels et les pulvérisations foliaires à base de nanoparticules.


Les graphiques représentant les moyennes et les médianes mettent également en évidence une augmentation progressive du rendement en grains entre les traitements B1, B2, B3, B4 et B5. Les deux premiers traitements présentent des valeurs très proches, alors qu'une augmentation importante est observée à partir du traitement B3. Les traitements B4 et B5 permettent d'obtenir les rendements moyens et médians les plus élevés, B5 apparaissant comme le traitement le plus performant.

Dans l'ensemble, ces représentations suggèrent que les pulvérisations foliaires sous forme de nanoparticules améliorent le rendement en grains du blé par rapport aux traitements Conventional et Magnetic. Les résultats indiquent une hiérarchie des performances ($B5 > B4 > B3 > B2 > B1$), avec Nano Mn (B5) comme traitement associé aux rendements les plus élevés.

✓ Répartition des traitements A et B

Afin de vérifier la répartition des observations entre les deux facteurs expérimentaux, Seed Priming (A) et Foliar Spray (B), plusieurs représentations ont été réalisées. Les diagrammes en barres, les diagrammes empilés et le tableau de contingence permettent de visualiser la distribution des combinaisons de traitements et de s'assurer que le plan expérimental est équilibré avant l'application des tests statistiques, notamment le test du χ^2 d'indépendance.





Les diagrammes en barres montrent que chacune des modalités du Seed Priming (A1 à A4) est associée au même nombre d'observations pour chacune des modalités du Foliar Spray (B1 à B5). Chaque combinaison $A \times B$ est représentée par quatre observations, ce qui traduit une répartition parfaitement équilibrée des données.

Le diagramme empilé confirme cette homogénéité. Les cinq modalités du facteur B occupent exactement la même proportion au sein de chaque modalité du facteur A, indiquant que chaque traitement foliaire est représenté de manière identique dans chacun des niveaux de préconditionnement des semences.

Le tableau de contingence met également en évidence cette organisation expérimentale. Toutes les cellules présentent un effectif de 4, ce qui signifie que chacune des 20 combinaisons de traitements (4 modalités de A $\times$ 5 modalités de B) possède exactement le même nombre de répétitions. Aucune combinaison n'est sous- ou surreprésentée.

Dans l'ensemble, ces résultats montrent que le plan expérimental est totalement équilibré, avec une distribution uniforme des observations entre les deux facteurs expérimentaux.


Remarque : Ces graphiques ne montrent pas que les traitements A et B sont indépendants biologiquement. Ils montrent simplement que le plan expérimental a été construit de façon équilibrée (4 répétitions pour chaque combinaison $A \times B$). L'indépendance statistique entre les deux facteurs sera évaluée dans la section consacrée au test du χ^2 .

✓ Matrice de corrélation entre les variables quantitatives

Afin d'étudier les relations linéaires entre les variables quantitatives du jeu de données, une matrice de corrélation de Pearson a été calculée. Les coefficients de corrélation varient entre -1 et $+1$, où une valeur proche de $+1$ traduit une forte corrélation positive, une valeur proche de -1 indique une forte corrélation négative, tandis qu'une valeur proche de 0 traduit une absence de relation linéaire. La matrice numérique ainsi que sa représentation sous forme de carte

thermique permettent d'identifier rapidement les variables qui évoluent dans le même sens ou en sens opposé.

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11
X1	1.000000	-0.926706	-0.922414	-0.924408	-0.910430	-0.929534	-0.841495	0.106182	-0.777869	-0.812801	-0.375363
X2	-0.926706	1.000000	0.922067	0.891719	0.878046	0.947127	0.792385	-0.030354	0.731419	0.763112	0.279469
X3	-0.922414	0.922067	1.000000	0.928504	0.917508	0.907319	0.881327	-0.044673	0.825769	0.857295	0.317021
X4	-0.924408	0.891719	0.928504	1.000000	0.950756	0.916402	0.911864	-0.055020	0.877922	0.899123	0.355255
X5	-0.910430	0.878046	0.917508	0.950756	1.000000	0.898331	0.942780	-0.144718	0.884349	0.917692	0.449122
X6	-0.929534	0.947127	0.907319	0.916402	0.898331	1.000000	0.856324	-0.027684	0.806564	0.834102	0.310989
X7	-0.841495	0.792385	0.881327	0.911864	0.942780	0.856324	1.000000	-0.105014	0.964064	0.988324	0.429092
X8	0.106182	-0.030354	-0.044673	-0.055020	-0.144718	-0.027684	-0.105014	1.000000	-0.128421	-0.118956	-0.916746
X9	-0.777869	0.731419	0.825769	0.877922	0.884349	0.806564	0.964064	-0.128421	1.000000	0.992968	0.429291
X10	-0.812801	0.763112	0.857295	0.899123	0.917692	0.834102	0.988324	-0.118956	0.992968	1.000000	0.432542
X11	-0.375363	0.279469	0.317021	0.355255	0.449122	0.310989	0.429092	-0.916746	0.429291	0.432542	1.000000



La matrice de corrélation révèle de nombreuses relations fortes entre les variables agronomiques étudiées. Les variables liées à la croissance de la plante, aux composantes du rendement et à la qualité du grain présentent généralement des corrélations positives élevées, indiquant qu'elles évoluent simultanément.

La hauteur de la plante (X3) est fortement corrélée au rendement en grains (X7) ($r = 0,881$), ce qui confirme que les plantes les plus hautes tendent à produire un rendement plus important. De même, X4 (Spike Density), X5 (Seeds per Spike) et X6 (Thousand Seed Weight) présentent également de fortes corrélations positives avec X7, soulignant leur contribution au rendement.

Les variables relatives à la qualité du grain montrent également des associations très fortes. En particulier, le rendement en grains (X7) est presque parfaitement corrélé au rendement protéique (X10) ($r = 0,988$), tandis que le pourcentage de protéines (X9) est très fortement corrélé à X10 ($r = 0,993$). Ces résultats indiquent qu'une augmentation du rendement en grains s'accompagne généralement d'une augmentation du rendement protéique.

À l'inverse, X1 (Spike Emergence) présente des corrélations négatives élevées avec la plupart des variables agronomiques, notamment avec X2, X3, X4, X5, X6 et X7 (coefficients compris entre $-0,84$ et $-0,93$). Cela signifie que des valeurs élevées de X1 sont généralement associées à des valeurs plus faibles de ces caractères.

La variable X8 (Biological Yield) se distingue des autres variables. Elle présente des corrélations très faibles avec la majorité des caractères agronomiques, mais une forte corrélation négative avec l'indice de récolte (X11) ($r = -0,917$). Cette relation est cohérente puisque l'indice de récolte correspond au rapport entre le rendement en grains et la biomasse totale : une augmentation importante de la biomasse, sans augmentation proportionnelle du rendement en grains, entraîne une diminution de cet indice.

La carte thermique confirme visuellement ces observations. Les cellules rouges foncées mettent en évidence les fortes corrélations positives entre les composantes du rendement et les variables de qualité du grain, tandis que les cellules bleues foncées traduisent les fortes corrélations négatives observées principalement entre X1 et les autres variables, ainsi qu'entre X8 et X11.

Dans l'ensemble, cette analyse montre que les variables étudiées sont fortement interdépendantes. Les caractères liés à la croissance, aux composantes du rendement et à la qualité du grain évoluent globalement dans le même sens, alors que X1 et X8 présentent un comportement distinct vis-à-vis des autres variables.

4.5. Application d'un test d'hypothèse

Afin de vérifier si les tendances observées lors de l'analyse descriptive correspondent à des différences ou à des relations statistiquement significatives, plusieurs tests d'hypothèse ont été réalisés. Les analyses ont été effectuées avec un seuil de signification fixé à $\alpha = 0,05$. Lorsque la p-value est inférieure à 0,05, l'hypothèse nulle (H_0) est rejetée au profit de l'hypothèse alternative (H^1). Dans le cas contraire, H_0 est conservée, indiquant que les différences ou relations observées peuvent être attribuées au hasard.

Les tests appliqués sont :

- Le coefficient de corrélation de Pearson pour évaluer les relations linéaires entre variables quantitatives ;
- L'analyse de variance (ANOVA) pour comparer les moyennes du rendement en grains selon les traitements de Seed Priming ;
- Le test du Khi-deux pour étudier l'indépendance entre les facteurs Seed Priming (A) et Foliar Spray (B).

✓ **Corrélation de Pearson**

Hypothèses :

H_0 : Il n'existe pas de corrélation significative entre X3 et X7.

H_1 : Il existe une corrélation significative entre X3 et X7.

Résultats

Coefficient de Pearson (r)	p-value	Décision
0,881	$4,09 \times 10^{-27}$	Rejet de H_0

Le coefficient de corrélation de Pearson est de $r = 0,881$, indiquant une forte corrélation linéaire positive entre la hauteur des plantes et le rendement en grains. La p-value obtenue ($4,09 \times 10^{-27}$) est largement inférieure au seuil de signification de 0,05. L'hypothèse nulle est donc rejetée. Ces résultats montrent que l'augmentation de la hauteur des plantes est significativement associée à une augmentation du rendement en grains. Cette relation confirme les observations réalisées lors de l'analyse graphique.

Hypothèses :

H_0 : Il n'existe pas de corrélation significative entre X7 et X10.

H_1 : Il existe une corrélation significative entre X7 et X10.

Résultats

Coefficient de Pearson (r)	p-value	Décision
0,988	$1,68 \times 10^{-65}$	Rejet de H_0

Le coefficient de Pearson obtenu ($r = 0,988$) met en évidence une corrélation positive extrêmement forte entre le rendement en grains et le rendement protéique. La p-value ($1,68 \times 10^{-65}$) est très inférieure à 0,05, ce qui conduit au rejet de l'hypothèse nulle. Ces résultats

indiquent que les parcelles présentant un rendement en grains élevé tendent également à présenter un rendement protéique élevé. Cette relation est statistiquement très significative.

✓ Analyse de variance (ANOVA)

Hypothèses :

H_0 : Les moyennes du rendement en grains (X7) sont identiques pour tous les niveaux de Seed Priming.

H_1 : Au moins un niveau de Seed Priming présente une moyenne différente.

Résultats

Statistique F	p-value	Décision
1,873	0,141	H_0 non rejetée

L'analyse de variance donne une statistique $F = 1,873$ avec une p-value de 0,141, supérieure au seuil de 0,05. L'hypothèse nulle ne peut donc pas être rejetée. Bien que l'analyse descriptive ait montré une augmentation progressive des rendements moyens du traitement A1 (Contrôle) vers A4 (0,3 % $ZnSO_4$), cette différence n'est pas statistiquement significative au seuil de 5 %. Les variations observées entre les traitements de Seed Priming peuvent donc être attribuées à la variabilité des données.

✓ Test du Khi-deux d'indépendance

Hypothèses :

H_0 : Le Seed Priming (A) et les Foliar Sprays (B) sont indépendants.

H_1 : Il existe une relation entre le Seed Priming (A) et les Foliar Sprays (B).

Résultats

χ^2	ddl	p-value	Décision
0,000	12	1,000	H_0 non rejetée

Le test du Khi-deux fournit une statistique $\chi^2 = 0$ avec une p-value égale à 1,00. Cette valeur étant largement supérieure au seuil de signification de 0,05, l'hypothèse nulle n'est pas rejetée. Ce résultat indique qu'aucune association statistiquement significative n'existe entre les facteurs Seed Priming (A) et Foliar Sprays (B). Cette conclusion est cohérente avec le plan expérimental, dans lequel chaque niveau de Seed Priming est combiné de manière équilibrée avec chacun des traitements de pulvérisation foliaire.

	Test	Question étudiée	H0	H1	p-value	Décision
0	ANOVA	Le rendement en grains (X7) varie-t-il selon le Seed Priming (A) ?	Les moyennes de X7 sont identiques pour tous les niveaux de Seed Priming.	Au moins une moyenne de X7 diffère selon le Seed Priming.	1.412290e-01	On ne rejette pas H0 : le résultat n'est pas statistiquement significatif.
1	Khi-deux	Existe-t-il une relation entre le Seed Priming (A) et les Foliar Sprays (B) ?	Le Seed Priming et les Foliar Sprays sont indépendants.	Il existe une relation entre le Seed Priming et les Foliar Sprays.	1.000000e+00	On ne rejette pas H0 : le résultat n'est pas statistiquement significatif.
2	Corrélation de Pearson	La hauteur des plantes (X3) est-elle liée au rendement en grains (X7) ?	Il n'existe pas de corrélation significative entre X3 et X7.	Il existe une corrélation significative entre X3 et X7.	4.089907e-27	On rejette H0 : le résultat est statistiquement significatif.
3	Corrélation de Pearson	Le rendement en grains (X7) est-il lié au rendement protéique (X10) ?	Il n'existe pas de corrélation significative entre X7 et X10.	Il existe une corrélation significative entre X7 et X10.	1.680602e-65	On rejette H0 : le résultat est statistiquement significatif.

Ce tableau présente une synthèse des différents tests statistiques réalisés afin d'évaluer les relations entre les variables étudiées et l'effet des traitements appliqués. Les résultats montrent que les deux tests de corrélation de Pearson sont hautement significatifs ($p < 0,001$), indiquant une forte relation positive entre la hauteur des plantes (X3) et le rendement en grains (X7), ainsi qu'entre le rendement en grains (X7) et le rendement protéique (X10). Ces résultats confirment que l'amélioration de la croissance des plantes est associée à une augmentation du rendement, et qu'un rendement en grains élevé s'accompagne généralement d'un rendement protéique plus important. En revanche, l'analyse de variance (ANOVA) montre que les différences observées entre les niveaux de Seed Priming (A) ne sont pas statistiquement significatives ($p = 0,141$). De même, le test du Khi-deux indique qu'il n'existe pas d'association significative entre les facteurs Seed Priming (A) et Foliar Sprays (B) ($p = 1,000$), ce qui confirme que ces deux facteurs sont indépendants dans le plan expérimental. Dans l'ensemble, les analyses statistiques mettent en évidence que les variables agronomiques quantitatives présentent de fortes relations entre elles, tandis que les effets des traitements étudiés ne se traduisent pas par des différences statistiquement significatives au seuil de 5 %.

✓ Application d'une ACP (Analyse en Composantes Principales)

L'Analyse en Composantes Principales (ACP) est une méthode statistique multivariée utilisée pour réduire la dimension d'un jeu de données tout en conservant la plus grande partie possible de l'information initiale. Elle transforme les variables quantitatives d'origine en nouvelles variables non corrélées, appelées composantes principales. Dans cette étude, l'ACP a été appliquée aux onze variables quantitatives X1 à X11 afin de résumer leur variabilité, d'identifier les variables qui contribuent le plus à la structuration des données et de visualiser la répartition des observations selon les traitements expérimentaux.

Avant l'application de l'ACP, les variables ont été standardisées à l'aide de la classe StandardScaler. Cette étape permet de centrer chaque variable autour de zéro et de la réduire à une variance égale à un. Elle est indispensable ici, car les variables sont exprimées dans des

unités et des échelles très différentes, par exemple en jours, en centimètres, en kilogrammes par hectare ou en pourcentage.

Deux analyses complémentaires ont ensuite été réalisées : une ACP à deux composantes pour obtenir une représentation bidimensionnelle des observations selon les traitements de Seed Priming, puis une ACP à trois composantes afin d'améliorer la restitution de la variance totale et de produire une projection tridimensionnelle.

✓ ACP à deux composantes principales

L'Analyse en Composantes Principales (ACP) a tout d'abord été réalisée en retenant les deux premières composantes principales (PC1 et PC2). Ces deux axes résument à eux seuls une grande partie de la variabilité des données. La première composante (PC1) explique 75,41 % de la variance totale, tandis que la deuxième composante (PC2) explique 16,38 %. Ensemble, ces deux composantes représentent 91,79 % de la variance totale, ce qui indique que le plan factoriel PC1-PC2 fournit une représentation fidèle de la structure du jeu de données.

Variance expliquée : [0.75405865 0.16379863]


L'analyse des coefficients des variables montre que PC1 est principalement associée aux variables décrivant la croissance, le rendement et la qualité des plantes, telles que la hauteur des plantes (X3), la densité des épis (X4), le nombre de graines par épi (X5), le poids de mille grains (X6), le rendement en grains (X7), le pourcentage de protéines (X9) et le rendement protéique (X10). En revanche, la variable X1 (Spike Emergence) est négativement corrélée à cette composante, traduisant une évolution opposée. La deuxième composante (PC2) est essentiellement définie par le rendement biologique (X8), qui présente un coefficient positif élevé (0,726), et par l'indice de récolte (X11), dont le coefficient est fortement négatif (-0,656). Cette composante met ainsi en évidence une opposition entre ces deux variables.

Contribution des variables :

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11
PC1	-0.326607	0.316476	0.329730	0.336122	0.338531	0.326768	0.333077	-0.054388	0.320604	0.328728	0.159192
PC2	-0.049917	0.117952	0.096252	0.075670	0.000454	0.107231	0.009729	0.725808	-0.013366	-0.003302	-0.655764

La projection des observations sur le plan factoriel PC1–PC2 montre une répartition progressive des traitements de Seed Priming (A) le long de la première composante. Les observations appartenant au traitement A1 (Control) sont principalement situées dans la partie négative de PC1, tandis que celles du traitement A4 (0,3 % ZnSO₄) se retrouvent majoritairement dans la partie positive. Les traitements A2 (0,1 % ZnSO₄) et A3 (0,2 % ZnSO₄) occupent des positions intermédiaires. Cette organisation suggère une amélioration progressive des caractéristiques

agronomiques avec l'augmentation de la concentration en ZnSO_4 . Toutefois, un chevauchement entre les groupes est observé, indiquant que le facteur Seed Priming n'explique pas à lui seul toute la variabilité des observations.



✓ ACP à trois composantes principales

Afin d'obtenir une représentation plus complète de la structure du jeu de données, une seconde Analyse en Composantes Principales a été réalisée en considérant les trois premières composantes principales (PC1, PC2 et PC3).

Les résultats montrent que les trois premières composantes expliquent respectivement 75,41 %, 16,38 % et 4,82 % de la variance totale. La variance cumulée atteint ainsi 96,60 %, indiquant que ces trois axes résument presque toute l'information contenue dans les onze variables quantitatives.

```
Variance expliquée : [0.75405865 0.16379063 0.04818871]
Variance expliquée cumulée : 0.9660379856575707
```


Le tableau des coefficients des variables montre que PC3 est principalement associée au pourcentage de protéines (X9), au rendement protéique (X10), au rendement en grains (X7) et à l'émergence des épis (X1), tandis qu'elle est négativement liée au nombre de jours jusqu'à la récolte (X2). Toutefois, cette composante n'explique qu'une faible proportion de la variance

totale (4,82 %) et son influence reste donc secondaire par rapport aux deux premières composantes.

Contribution des variables :											
	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10	X11
PC1	-0.326607	0.316476	0.329730	0.336122	0.338531	0.326768	0.333077	-0.054388	0.320604	0.328728	0.159192
PC2	-0.049917	0.117952	0.096252	0.075670	0.000454	0.107231	0.009729	0.725808	-0.013366	-0.003302	-0.655764
PC3	0.340237	-0.454458	-0.174214	-0.035770	0.014695	-0.263685	0.347869	0.156702	0.491269	0.434995	-0.014051

La projection tridimensionnelle des observations confirme les résultats obtenus avec l'ACP à deux composantes. La majorité des individus demeure organisée principalement selon PC1, qui constitue l'axe dominant de variation. L'ajout de PC3 permet toutefois de mieux visualiser certaines différences entre les observations et de distinguer plus facilement les individus atypiques, sans modifier l'organisation générale des données.

Projection 3D des observations par ACP



Dans l'ensemble, l'ACP à trois composantes confirme que les deux premières composantes résument déjà l'essentiel de la variabilité du jeu de données, tandis que la troisième composante apporte une information complémentaire plus limitée.

5. Interprétation des Résultats et Conclusion

L'analyse statistique réalisée à l'aide de Python a permis d'explorer de manière approfondie les effets du Seed Priming (A) et Foliar Spray (B) sur plusieurs caractères agronomiques du blé. Les différentes étapes de l'analyse, allant de l'exploration des données jusqu'à l'Analyse en Composantes Principales (ACP), ont permis de mieux comprendre la structure du jeu de données et les relations existant entre les variables étudiées.

L'analyse descriptive a montré que les variables quantitatives présentent des niveaux de variabilité différents selon les traitements appliqués. Les histogrammes et les diagrammes en boîte ont permis d'identifier la distribution des observations et de mettre en évidence certaines différences entre les groupes expérimentaux.

L'étude des corrélations a révélé l'existence de relations entre plusieurs variables agronomiques. En particulier, une corrélation positive a été observée entre la hauteur des plantes (X3) et le rendement en graines (X7), indiquant que les plantes les plus développées tendent à produire un rendement plus élevé. De même, le rendement en graines (X7) est positivement associé au rendement protéique (X10), ce qui confirme que l'augmentation de la production de graines contribue directement à une amélioration de la production totale de protéines.

Le test d'ANOVA a permis d'évaluer l'effet du Seed Priming sur le rendement en graines. Les résultats montrent que les différences observées entre les traitements peuvent être évaluées statistiquement afin de déterminer si elles sont significatives, ce qui constitue un outil essentiel pour comparer l'efficacité des différents traitements appliqués.

Le test du Khi-deux a permis d'étudier la relation entre les variables qualitatives Seed Priming (A) et Foliar Sprays (B). Ce test complète l'analyse descriptive en vérifiant statistiquement l'existence ou non d'une association entre ces deux facteurs expérimentaux.

Enfin, l'Analyse en Composantes Principales (ACP) a permis de réduire la dimension du jeu de données tout en conservant une grande partie de l'information initiale. Les premières composantes principales expliquent la majeure partie de la variabilité totale, ce qui facilite la visualisation des relations entre les variables et des similitudes entre les traitements. Cette

méthode met également en évidence les variables qui contribuent le plus à la variabilité observée.

En conclusion, ce projet démontre l'intérêt de l'utilisation de Python pour l'analyse de données agronomiques. Les différentes méthodes statistiques et graphiques mises en œuvre permettent non seulement de décrire le jeu de données, mais également de mettre en évidence les relations entre les variables et d'évaluer l'effet des traitements appliqués. Cette approche fournit une base solide pour l'interprétation des résultats expérimentaux et facilite la prise de décision dans les études agronomiques. Plus largement, ce travail illustre l'apport des outils de science des données dans la valorisation des expérimentations agricoles et dans l'aide à l'amélioration des pratiques culturales.

6. Références

1. R. Munns, M. Tester, Mechanisms of salinity tolerance, *Annualreviews.Org* 59 (2008) 651–681. <https://doi.org/10.1146/annurev.arplant.59.032607.092911>.
2. M. Farooq, H. Bramley, J. Palta, K.H.M. Siddique, Heat stress in wheat during reproductive and grain-filling phases, *CRC. Crit. Rev. Plant Sci.* 30 (2011) 491–507. <https://doi.org/10.1080/07352689.2011.615687>.
3. M. Hasanuzzaman, M.R.H. Raihan, A.A.C. Masud, K. Rahman, F. Nowroz, M. Rahman, K. Nahar, M. Fujita, Regulation of reactive oxygen species and antioxidant defense in plants under salinity, *Int. J. Mol. Sci.* 22 (2021) 9326. <https://doi.org/10.3390/ijms22179326>.
4. N. Mishra, C. Jiang, L. Chen, A. Paul, A. Chatterjee, G. Shen, Achieving abiotic stress tolerance in plants through antioxidative defense mechanisms, *Front. Plant Sci.* 14 (2023). <https://doi.org/10.3389/FPLS.2023.1110622/FULL>.
5. N. Bhagat, M. Raghav, S. Dubey, N. Bedi, Bacterial exopolysaccharides: Insight into their role in plant abiotic stress tolerance, *J. Microbiol. Biotechnol.* 31 (2021) 1045–1059. <https://doi.org/10.4014/jmb.2105.05009>.
6. K. Parvin, K. Nahar, S.M. Mohsin, J. Al Mahmud, M. Fujita, M. Hasanuzzaman, Plant phenolic compounds for abiotic stress tolerance, in: *Managing Plant Production under Changing Environment*, Springer Nature, 2022: pp. 193–237. https://doi.org/10.1007/978-981-16-5059-8_8/FIGURES/9.
7. K. Kumar, P. Debnath, S. Singh, N. Kumar, An overview of plant phenolics and their involvement in abiotic stress tolerance, *Stresses* 3 (2023) 570–585. <https://doi.org/https://doi.org/10.3390/stresses3030040>.

8. M. Han, S. Kasim, Z. Yang, X. Deng, N.B. Saidi, M.K. Uddin, E.M. Shuib, Plant Extracts as Biostimulant Agents: A Promising Strategy for Managing Environmental Stress in Sustainable Agriculture, *Phyton* (B. Aires). 93 (2024) 2149–2166. <https://doi.org/10.32604/phyton.2024.054009>.